II, Prediction

1, Ở key có dot product lớn nhất sẽ nhận attention weight lớn nhất vì softmax giữ thứ tự scores.

↳ Confidence: Cao

2, Vì scores [1,1,1,1], weight = [0,25; 0,25; 0,25; 0,25]

↳ Confidence: Cao

3, Vì score [1,1,10] attention gần như tập trung vào "10"

↳ Confidence: Cao

4, Attention ở phần lớn nào cũng tập trung vào token có nghĩa cho là quan trọng nhất.

↳ Confidence: Cao

5, Tăng từ 10 → 10000 token làm sao phần tử tăng 10 000 lần. Confidence: Cao

6, Transformer ở phần lớn nào cũng nhanh hơn RNN, self-attention có chi phí tăng theo bình phương độ dài chuỗi. Confidence: Cao